




SEQUENCE × STRUCTURE

ساختار سه‌بعدی × توالی



Structure-aware Protein Self-Supervised Learning

آگاهی از ساختار پروتئین و یادگیری خودنظارتی

ارائه بر اساس مقاله ▾

هدف ارائه 

فهم مفهومی، استخراج نکات کلیدی و پاسخ به چالش‌های ارائه

Can (Sam) Chen, Jingbo Zhou, Fan Wang, Xue Liu, Dejing Dou

McGill University · MILA · Baidu Research · BCG X

 Bioinformatics (2023) — Oxford Academic

مسئله و چرا این مقاله؟

چرا نمایش پروتئین ناقص است و چه کمبودهایی وجود دارد

⚠ چالش های موجود

◆ داده های کلیدی

۹۹٪

توالی پروتئین های شناخته شده بدون ساختار معتبر

۳۸۴

برای دسته بندی (C384) کلاس واکنش آنزیمی

۱۰×

هزینه آزمایشگاهی نسبت به شبیه سازی محاسباتی

➡ نادیده گرفتن ساختار سه بعدی

بیشتر مدل ها فقط از توالی آمینواسید استفاده می کنند و ساختار سه بعدی پروتئین را نادیده می گیرند، در حالی که عملکرد پروتئین مستقیماً به شکل فضایی آن وابسته است.

🕒 دقت پایین در تفسیر عملکرد

نمایش ناقص پروتئین منجر به دقت پایین در تفسیر عملکرد و دسته بندی واکنش های آنزیمی می شود که در کاربردهای زیستی حیاتی است.

🧪 کمبود داده های برجسب دار

باعث کمبود داده های برجسب دار پروتئین می شود که یادگیری (wet-lab) هزینه و زمان بالای آزمایش های آزمایشگاهی نظارت شده را محدود می کند.

راه حل نوآورانه (STEPS)

SStructure-awareE Protein Self-supervised Learning

Protein LM + GNN (مدل ترکیبی) ✦

ورود همزمان ساختار و توالی ✦


اطلاعات ساختاری سه‌بعدی و توالی آمینواسید به صورت همزمان وارد مدل می‌شوند تا نمایش غنی‌تری از پروتئین ساخته شود.

TASK 1 Distance Prediction ✦

یادگیری فاصله بین آمینو اسید ها

TASK 2 Angle Prediction

یادگیری و بازسازی زاویه‌های دیهدرال برای درک خمیدگی محلی



STEPS نمای کلی رویکرد — شکل ۱

اجزای معماری

۰۱

مدل سازی گراف پروتئین

نود ها: residue یال ها: فاصله کمتر از ۷ آنگستروم

۰۲

ورودی چندوجهی

edge feature + ویژگی زاویه ای + توالی embedding


۰۳

خروجی دو head

Distance Head + Angle Head

۰۴

همانگی GNN و PLM

Pseudo Bi-level Optimization + بین نمایش توالی و ساختار
GNN و PLM برای همانگی

دو تسک اصلی مدل

Distance + Angle

TASK 2

Angle Prediction



بازسازی زوایای دیهدرال ماسک شده

➤ بخشی از residue ها mask می شوند و زوایای دیهدرال (φ, ψ) بازسازی می شوند

➤ مدل خمیدگی محلی backbone را یاد می گیرد

➤ Loss: MSE (Mean Squared Error)

➤ نقش: ریزساختار فضایی و پیچیدگی محلی

$$= \sum (\varphi_i - \hat{\varphi}_i)^2 + (\psi_i - \hat{\psi}_i)^2$$

 L_{ang}

TASK 1

Distance Prediction



پیش بینی فاصله

➤ فاصله بین جفت residue ها به bin های مساوی تقسیم می شود

➤ مدل باید کلاس درست bin را پیش بینی کند (طبقه بندی چند کلاسه)

➤ Loss: Cross-Entropy

➤ نقش: شکل کلی backbone و چینش فضایی پروتئین

$$= \text{CrossEntropy}(d_{ij_class}, \hat{d}_{ij_class})$$

 L_{dis}

$$L = L_{dis} + L_{ang}$$

ترکیب خطای این دو، نمایش ساختاری غنی تر می دهد



مقایسه و مزیت‌ها

C384 BENCHMARK

%۶۵.۳۸

enzyme class (بهیود) %۳۶

C10 BENCHMARK

%۷۱.۰۵

cellular compartment prediction

C2 BENCHMARK

%۸۹.۶۱

membrane/non-membrane classification

benchmark دقت (%) — مقایسه روش‌ها



روش	C2	C10	C384
Pre-LM (sequence-only)	58.00	35.00	1.32
DeepFRI (structure+LM)	88.38	69.23	15.72
STEPS-w/oLM	77.82	42.51	3.89
STEPS	89.61	71.05	65.38

افت شدید کیفیت → PLM یا MI حذف هر تسک

برتری چشمگیر در ساختار،
(واکنش آنزیمی) C384

✓ structure-only و sequence-only از هر دو گروه بهتر عمل می‌کند

چالش‌ها و محدودیت‌ها

محدودیت‌های داده، هماهنگی و حساسیت به حذف اجزا

⊗ چهار چالش کلیدی

۰۱ کمبود داده ساختاری معتبر



تعداد پروتئین‌های دارای ساختار معتبر بسیار کمتر از توالی‌های موجود است، گلوگاه اصلی یادگیری ساختاری

۰۲ sequence و structure نیاز به هماهنگی دقیق



ترازسازی دقیق بین توالی و ساختار برای هر آمینو اسید ضروری است؛ در غیر اینصورت به افت کیفیت منجر می‌شود

۰۳ حساسیت به کیفیت ساختار



اگر ساختار معتبر نباشد یا ترکیب درست انجام نشود، عملکرد مدل به شدت افت می‌کند

۰۴ افت شدید → حذف هر جزء



حذف یکی از اجزا باعث افت قابل توجه دقت می‌شود، طراحی به هم پیوسته است

با تشکر از توجه شما ❤️

 Chen et al., Bioinformatics 2023