



Structure-aware Protein Self-Supervised Learning

یادگیری خودنظارتی آگاه از ساختار پروتئین

ارائه بر اساس مقاله استاد

هدف ارائه

فهم مفهومی، استخراج نکات کلیدی و پاسخ به چالش‌های ارائه

Can (Sam) Chen, Jingbo Zhou, Fan Wang, Xue Liu, Dejing Dou

McGill University · MILA · Baidu Research · BCG X

📖 Bioinformatics (2023) — Oxford Academic

مسئله و چرا این مقاله؟

چرا نمایش پروتئین ناقص است و چه کمبودهایی وجود دارد

▲ چالش‌های موجود

🔗 داده‌های کلیدی

۹۹٪

پروتئین‌های توالی‌شناخته‌شده بدون ساختار معتبر

۳۸۴

کلاس واکنش آنزیمی (C384) برای دسته‌بندی

۱۰×

هزینه wet-lab نسبت به شبیه‌سازی محاسباتی

نادرده گرفتن ساختار سه‌بعدی



بیشتر مدل‌ها فقط از توالی آمینواسید استفاده می‌کنند و ساختار سه‌بعدی پروتئین را نادیده می‌گیرند، در حالی که عملکرد پروتئین مستقیماً به شکل فضایی آن وابسته است.

دقت پایین در آنوتیشن عملکرد



نمایش ناقص پروتئین منجر به دقت پایین در آنوتیشن عملکرد و دسته‌بندی واکنش‌های آنزیمی می‌شود که در کاربردهای زیستی حیاتی است.

کمبود داده‌های برچسب‌دار



هزینه و زمان بالای آزمایش‌های آزمایشگاهی (wet-lab) باعث کمبود داده‌های برچسب‌دار پروتئین می‌شود که یادگیری نظارت‌شده را محدود می‌کند.

راه حل نوآورانه STEPS

SStructure-awarE Protein Self-supervised Learning

Protein LM + GNN: مدل ترکیبی: 

ورود همزمان ساختار و توالی



اطلاعات ساختاری سه بعدی و توالی آمینواسید به صورت همزمان وارد مدل می شوند تا نمایش غنی تری از پروتئین ساخته شود.

Distance Prediction TASK 1




یادگیری فاصله بین residueها در فضای سه بعدی برای درک شکل کلی backbone پروتئین.

Angle Prediction TASK 2



یادگیری و بازسازی زاویه های دیهدرال برای درک خمیدگی محلی backbone.

FIGURE 1 



شکل ۱ - نمای کلی رویکرد STEPS

معماری و روش مدل

مدل سازی گراف + Bi-level Optimization + Mutual Information

اجزای معماری

۰۱

مدل سازی گراف پروتئین

نودها: residue؛ یال: فاصله کمتر از 7Å



۰۲

ورودی چندوجهی

embedding توالی + ویژگی زاویه‌ای + edge feature (معکوس مجذور فاصله)



۰۳

دو head خروجی

Distance Head (طبقه‌بندی) + Angle Head (ممیزی زاویه)




۰۴

هماهنگی GNN و PLM

Mutual Information بین نمایش توالی و ساختار + Pseudo Bi-level Optimization برای هماهنگی GNN و PLM



FIGURE 3



شکل ۳ - معماری کامل مدل STEPS

دو تسک اصلی مدل

Distance + Angle – هرکدام جنبه‌ای از ساختار را رمزگذاری می‌کنند

TASK 2

Angle Prediction



بازسازی زوایای دیهدرال ماسک‌شده

- بخشی از **residue** ها **mask** می‌شوند و زوایای دیهدرال (φ, ψ) بازسازی می‌شوند
- مدل خمیدگی محلی **backbone** را یاد می‌گیرد
- **Loss: MSE (Mean Squared Error)**
- نقش: ریزساختار فضایی و هم‌پیچیدگی محلی

$$= \sum (\psi_i - \hat{\psi}_i)^2 + (\varphi_i - \hat{\varphi}_i)^2$$

L_{ang}

TASK 1

Distance Prediction



پیش‌بینی فاصله residue-residue

- فاصله بین جفت residue ها به **bin** های مساوی تقسیم می‌شود
- مدل باید کلاس درست **bin** را پیش‌بینی کند (طبقه‌بندی چندکلاسه)
- **Loss: Cross-Entropy**
- نقش: شکل کلی **backbone** و چینش فضایی پروتئین

$$= \text{CrossEntropy}(d_{ij_class}, \hat{d}_{ij_class})$$

L_{dis}

ترکیب این دو **Loss**، نمایش ساختاری غنی‌تر می‌دهد: $L = L_{dis} + L_{ang}$

Σ

مقایسه و مزیت‌ها

برتری چشمگیر STEPS بر baseline‌های sequence-only و structure-only

C384 BENCHMARK

۶۵.۳۸%

دقت در C384

(enzyme class بهبود نسبت به baseline ۳۶٪)

C10 BENCHMARK

۷۱.۰۵%

دقت در C10

cellular compartment prediction

C2 BENCHMARK

۸۹.۶۱%

دقت در C2

membrane/non-membrane classification

مقایسه روش‌ها – دقت (%) بر سه benchmark

روش	C2	C10	C384
Pre-LM (sequence-only)	58.00	35.00	1.32
DeepFRI (structure+LM)	88.38	69.23	15.72
STEPS-w/oLM	77.82	42.51	3.89
STEPS این کار	89.61	71.05	65.38

حذف هر تسک، MI یا PLM → افت شدید کیفیت ⚠

برتری چشمگیر در C384 (واکنش آنزیمی) – ساختار، سایت‌های اتصال را تعیین می‌کند ➡

STEPS از هر دو گروه sequence-only و structure-only بهتر عمل می‌کند ✓

چالش‌ها و محدودیت‌ها

محدودیت‌های داده، هماهنگی و حساسیت به حذف اجزا

چهار چالش کلیدی

FIGURE 4

structure effectively, which demonstrates strong performance on protein function prediction tasks. [Gligorijević et al. \(2021\)](#) leverage the LSTM model to encode the protein sequence and the GCN model to encode the protein tertiary structure for function prediction. [Somnath et al. \(2021\)](#) connect protein surface to structure modeling and sequence modeling where the learned representation achieves good performance on several downstream tasks.

5.2 Protein pretraining

There are a few studies to perform pretraining on protein sequences ([Bepler and Berger 2019](#); [Wang et al. 2023](#); [Zhou et al. 2023](#)). [Bepler and Berger \(2019\)](#) propose to train an LSTM on protein sequences, which could implicitly incorporate structural information from the global structural similarity between proteins and the contact maps for individual proteins, while STEPS uses novel self-supervised tasks to explicitly model protein structure. Our distance prediction task and the contact prediction task in [Bepler and Berger \(2019, 2021\)](#) can both incorporate the distance information into the learned protein representation. The difference is that the distance prediction task models the distance as a multi-class classification and this can explicitly consider more protein structural information compared with the binary classifi-

شکل ۴ - مطالعات ablation: افت عملکرد با حذف هر جزء

۰۱ کمبود داده ساختاری معتبر

تعداد پروتئین‌های دارای ساختار معتبر (AlphaFold/PDB) بسیار کمتر از توالی‌های موجود است - گلوگاه اصلی یادگیری ساختاری.

۰۲ نیاز به هماهنگی دقیق sequence و structure

ترازسازی دقیق بین توالی و ساختار برای هر residue ضروری است؛ خطای alignment به افت کیفیت منجر می‌شود.

۰۳ حساسیت به کیفیت ساختار

اگر ساختار معتبر نباشد یا ترکیب sequence-structure درست انجام نشود، عملکرد مدل به شدت افت می‌کند.

۰۴ حذف هر جزء -> افت شدید

حذف یکی از اجزا (PLM / mutual information / angle task / distance task) باعث افت قابل توجه دقت می‌شود - طراحی به هم پیوسته است.

جمع‌بندی و نتیجه‌گیری

نوآوری، نتایج و کاربرد

« STEPS برای اولین بار اطلاعات ساختاری را وارد خودنظارتی پروتئین می‌کند.

کاربرد عملی

ابزار مفید برای فهم عملکرد پروتئین در سناریوهای **lacks-label** — مناسب پژوهش‌های زیست‌شناسی و دارورسانی.

نتایج قدرتمند

برتری چشمگیر در سه **benchmark** (C2: ۸۹.۶۱٪، C10: ۷۱.۰۵٪، C384: ۶۵.۳۸٪) و کاربرد عملی برای وظایف زیستی.

نوآوری اصلی

تعریف دو وظیفه ساختاری (**Angle + Distance**)، معماری گرافی **GNN**، و **Pseudo Bi-level Optimization** برای انتقال دانش **PLM** به **GNN**.

📖 Chen et al., Bioinformatics 2023



با تشکر از توجه شما